

UNIVERSITÀ POLITECNICA DELLE MARCHE

INGEGNERIA INFORMATICA E
DELL'AUTOMAZIONE

Corso di
DATA SCIENCE




**Segmentazione e previsione del successo
accademico di studenti americani**

**Forecasting della generazione elettrica ed
emissioni di CO₂**

Docenti:

Domenico Ursino
Christofer Buratti



Studenti:

Matteo Copertari
Kevin Giusti
Matteo Stronati
Jacopo Tarulli

Anno accademico 2025-2026

Indice

1	Introduzione	5
1.1	Contesto e obiettivi del progetto	5
1.2	Strumenti e librerie utilizzati	6
2	Dataset utilizzati	7
2.1	College Student Placement	7
2.1.1	ETL (Extract, Transform, Load)	8
2.2	US Electricity Generation & Emissions	8
3	Analisi descrittiva Dataset Studenti	9
3.1	Distribuzione delle Variabili	9
3.1.1	Distribuzione delle variabili	9
3.2	Analisi della Correlazione e Multicollinearità	13
3.2.1	Identificazione della Multicollinearità	13
3.2.2	Analisi delle Correlazioni con il Placement	14
3.2.3	L'Anomalia della Variabile Academic_Performance	14
4	Clustering	15
4.1	Algoritmo K-means	15
4.1.1	Ricerca del numero ottimale di cluster	15
4.1.2	Analisi dei risultati e profilazione dei cluster	15
4.2	DBSCAN	18
4.2.1	Determinazione degli iperparametri	18
4.2.2	Analisi dei risultati ottenuti	19
4.3	Clusterizzazione Gerarchica	20
4.3.1	Analisi del Dendrogramma	20
4.3.2	Risultati e Visualizzazione tramite PCA	21
4.3.3	Analisi dei profili	22
4.3.4	Impatto sul Placement	23
5	Classificazione	24
5.1	Importanza delle Feature	24
5.2	Processo di Classificazione	25
5.2.1	Modelli	25
5.2.2	Risultati Preliminari (Senza Ottimizzazione)	26
5.2.3	Ottimizzazione dei Modelli (Grid Search)	26
5.2.4	Confronto Finale dei Risultati	27
5.2.5	Commento ai risultati	27

6	Analisi di serie temporali	28
6.1	Introduzione	28
6.2	Analisi preliminari	28
6.2.1	Mappe coropletiche informative	29
6.2.2	Grafici di evoluzione temporale degli stati	31
6.2.3	Correlazione tra generazione elettrica ed emissioni	33
6.2.4	Evoluzione del mix energetico negli Stati Uniti	34
6.3	Analisi della Generazione di Elettricità	36
6.3.1	Analisi Esplorativa e Decomposizione	36
6.3.2	Verifica della Stazionarietà	38
6.3.3	Modellazione SARIMA e Validazione	40
6.3.4	Diagnostica dei Residui	41
6.3.5	Previsione Futura (2025-2026)	42
6.4	Analisi delle Emissioni di CO ₂	44
6.4.1	Analisi Esplorativa e Decomposizione	44
6.4.2	Verifica della Stazionarietà	46
6.4.3	Modello 1: SARIMA	46
6.4.4	Analisi Variabili Esogene	47
6.4.5	Modello 2: SARIMAX	48
6.4.6	Previsione Futura con Focus 2025-2026	50
6.4.7	Diagnostica e previsione completa	50

Elenco delle figure

3.1	Distribuzione Placement	9
3.2	Distribuzione IQ	10
3.3	Distribuzione CGPA	11
3.4	Distribuzione Internship	11
3.5	Distribuzione variabili cognitive e di rendimento accademico	12
3.6	Distribuzione delle variabili relative alle competenze e performance degli studenti.	12
3.7	Magrice di correlazione	13
4.1	Elbow Method e Analisi Silhouette	15
4.2	Heatmap delle medie delle feature per cluster	16
4.3	Tasso di Placement per cluster	17
4.4	Clustering K-Means	17
4.5	K-Distance	18
4.6	Clustering DBSCAN	19
4.7	Profilazione DBSCAN	19
4.8	Rateo Placemete DBSCAN	20
4.9	Dendogramma	21
4.10	Visualizzazione Cluster Gerarchici	22
4.11	Profili HC	22
4.12	Placement Rate HC	23
5.1	Importanza Feature	25
6.1	Mappe coropletiche degli Stati Uniti sulle emissioni di CO ₂	29
6.2	Mappe coropletiche degli Stati Uniti sulla produzione di elettricità rinnovabile	30
6.3	Mappe coropletiche degli Stati Uniti sull'intensità carbonica	31
6.4	Evoluzione temporale degli stati con più emissioni di CO ₂	32
6.5	Evoluzione temporale degli stati con più generazione di elettricità	32
6.6	Scatter plot di generazione elettrica ed emissioni di CO ₂	34
6.7	Grafici a torta di mix energetici negli Stati Uniti	35
6.8	Andamento temporale della generazione di elettricità USA (2001-2024)	36
6.9	Decomposizione della serie storica (Trend, Stagionalità, Residui)	37
6.10	Pattern stagionale mensile della generazione elettrica	38
6.11	ACF e PACF della serie originale (Non Stazionaria)	39
6.12	ACF e PACF della serie differenziata (Stazionaria)	40
6.13	Validazione del modello SARIMA sulla generazione elettrica	41

6.14 Diagnostica dei residui del modello SARIMA	42
6.15 Previsione futura con modello SARIMA	43
6.16 Panoramica delle emissioni	45
6.17 Pattern stagionale mensile delle emissioni	46
6.18 Analisi di autocorrelazione	46
6.19 Validazione del modello SARIMA (Univariato)	47
6.20 Variabili esogene: Generazione totale, Rinnovabili e Fossili	48
6.21 Validazione del modello SARIMAX (Multivariato)	49
6.22 Previsione emissioni per i prossimi 24 mesi (Focus 2025-2026)	50
6.23 Diagnostica dei residui	51
6.24 Previsione finale completa (2001-2026)	52

1 Introduzione

La **Data Science** rappresenta oggi uno degli strumenti fondamentali per l'analisi e l'interpretazione dei dati provenienti da contesti eterogenei. Tra i compiti più rilevanti in questo ambito rientrano la classificazione, il clustering e l'analisi delle serie temporali, ciascuno con un ruolo cruciale nell'estrazione di conoscenza utile dai dati.

La **classificazione** consiste nel costruire un modello predittivo capace di assegnare a ogni osservazione una classe o categoria sulla base di un processo di addestramento effettuato su dati di training. Il modello apprende le relazioni tra le variabili esplicative e le etichette note del dataset di addestramento, così da poter successivamente prevedere la classe di nuove osservazioni non viste.

Il **clustering**, invece, è una tecnica non supervisionata che mira a raggruppare elementi simili tra loro in insiemi (cluster) distinti, senza una conoscenza preventiva delle etichette. È impiegato per scoprire strutture nascoste nei dati e per definire profili o pattern di comportamento.

Infine, l'**analisi delle serie temporali** si concentra su dati osservati nel tempo, con l'obiettivo di modellare tendenze, stagionalità e variazioni, permettendo di effettuare previsioni e valutare l'evoluzione di fenomeni dinamici come, in questo caso, l'andamento della produzione energetica o i livelli di inquinamento.

1.1 Contesto e obiettivi del progetto

L'attività svolta si è concentrata sull'analisi di due dataset distinti, ognuno dedicato a specifici task di data science. Il primo dataset riguarda informazioni sugli **studenti dei college americani** ed è stato utilizzato per le attività di classificazione e clustering. Il secondo dataset, invece, contiene dati storici relativi ai **consumi energetici** e ai **livelli di inquinamento** negli Stati Uniti, usato per lo studio delle serie temporali. In particolare:

- **Dataset "College Student Placement":** L'obiettivo di questa parte è stato analizzare le caratteristiche principali che descrivono gli studenti, individuando pattern comuni e differenze tra i vari profili accademici. In particolare, il clustering ha permesso di raggruppare gli studenti in insiemi omogenei sulla base delle loro caratteristiche, mentre la classificazione è stata utilizzata per addestrare modelli predittivi in grado di assegnare nuove osservazioni a una delle classi individuate.

- **Dataset "US Electricity Generation & Emissions"**: Questa sezione dell'analisi si è concentrata sullo studio dell'evoluzione temporale di variabili legate ai consumi energetici e ai livelli di inquinamento nel tempo. L'obiettivo è stato modellare le tendenze, identificare fenomeni di stagionalità e generare previsioni sull'andamento futuro di consumo e emissioni, fornendo così indicazioni utili per la pianificazione energetica e la sostenibilità ambientale.

Attraverso queste due analisi, il progetto intende mostrare l'applicazione integrata di diverse tecniche di data science su contesti differenti, evidenziando come la combinazione di modelli predittivi e analisi esplorative possa offrire una comprensione più completa e informata dei fenomeni studiati.

1.2 Strumenti e librerie utilizzati

Tutte le analisi e i modelli sono stati sviluppati utilizzando il linguaggio di programmazione **Python**, grazie alla sua ampia disponibilità di librerie per la manipolazione, visualizzazione e modellazione dei dati. Le principali librerie e strumenti impiegati sono:

- **Pandas** e **NumPy** per la gestione e trasformazione del dataset;
- **Matplotlib** e **Seaborn** per la visualizzazione statistica e grafica dei dati;
- **Scikit-learn** per l'implementazione di algoritmi di classificazione, clustering e metriche di valutazione;
- **Statsmodels** per l'analisi e la modellazione delle serie temporali;
- **Plotly** per la creazione di grafici interattivi;
- **Jupyter Notebook** come ambiente interattivo di sviluppo e documentazione.

Questi strumenti permettono di coprire l'intero ciclo di vita del progetto, dall'analisi esplorativa alla costruzione dei modelli predittivi, fino alla valutazione e interpretazione dei risultati.

2 Dataset utilizzati

Il presente capitolo descrive in dettaglio i dataset impiegati nell’ambito del progetto, con l’obiettivo di fornire un quadro chiaro delle informazioni di partenza e delle principali scelte effettuate in fase di analisi. In particolare, sono stati utilizzati due dataset distinti, ciascuno associato a specifici task di data science ed a differenti obiettivi sperimentali. Entrambi i dataset utilizzati sono stati reperiti attraverso una ricerca nella piattaforma **Kaggle**.

Il primo dataset è ”**College Student Placement**”, riguarda gli studenti di college americani e costituisce la base per le attività di classificazione e clustering, permettendo di analizzare profili accademici e cognitivi.

Il secondo dataset, invece, è ”**US Electricity Generation & Emissions**” e contiene dati relativi ai consumi energetici e ai livelli di inquinamento nel corso del tempo negli Stati Uniti, ed è stato impiegato per lo studio e la modellazione di serie temporali.

Nei paragrafi successivi verranno presentate in modo più approfondito la struttura dei dataset, le variabili disponibili e le principali operazioni preliminari svolte, come eventuali pulizie, trasformazioni e selezioni delle feature rilevanti.

2.1 College Student Placement

Il dataset oggetto dello studio è finalizzato all’analisi dei fattori che influenzano il collocamento lavorativo (placement) degli studenti universitari. Raccoglie informazioni relative a 10.000 studenti, strutturate in 10 colonne che descrivono il profilo cognitivo, accademico e professionale di ogni individuo. Nel dettaglio, le informazioni contenute nel dataset sono:

- **Identificativi:**

- *College_ID*: Stringa alfanumerica che identifica il college di provenienza.

- **Indicatori Cognitivi e Accademici:**

- *IQ*: Punteggio del quoziente intellettivo dello studente.
- *Prev_Sem_Result*: Risultato numerico ottenuto nel semestre precedente.
- *CGPA*: Media dei voti cumulativa (Cumulative Grade Point Average).
- *Academic_Performance*: Valutazione sintetica del rendimento su una scala da 1 a 10.

- **Competenze ed Esperienze**

- *Internship_Experience*: Variabile categorica che indica la presenza di tirocini svolti.
- *Projects_Completed*: Numero di progetti accademici o extra-accademici portati a termine.
- *Extra_Curricular_Score*: Punteggio relativo alla partecipazione ad attività extra-curricolari.
- *Communication_Skills*: Valutazione delle abilità comunicative.

- **Variabile Target**

- *Placement*: Esito del processo di selezione lavorativa (Yes/No).

2.1.1 ETL (Extract, Transform, Load)

Per rendere il dataset idoneo alla successiva analisi computazionale, è stata effettuata una fase di preprocessing:

- **Codifica delle Variabili Categoriche**: Le colonne *Placement* e *Internship_Experience*, originariamente in formato testuale ("Yes"/"No"), sono state mappate in valori booleani (1 e 0) per permettere l'applicazione di algoritmi matematici.
- **Pulizia del Dataset**: È stata verificata l'integrità dei dati; il dataset non presenta valori nulli (missing values), garantendo la solidità statistica delle analisi.

2.2 US Electricity Generation & Emissions

Il dataset utilizzato per l'analisi delle serie temporali è "US Electricity Generation & Emissions". Esso contiene dati mensili sulla produzione elettrica e le emissioni del settore energetico negli Stati Uniti, coprendo tutti i 50 stati e i territori dal 2001 fino a quasi tutto il 2025, con anche righe aggregate a livello nazionale sotto la dicitura "US Total". Ogni osservazione specifica lo stato, la data mensile, la categoria principale, la sottocategoria, la variabile energetica, l'unità di misura e il valore numerico, inclusi cambiamenti YoY, per un'analisi multidimensionale del mix energetico.

Per le previsioni di serie temporali, ci si è concentrati esclusivamente su *Total Generation (GWh)* per la produzione elettrica totale e *Total emissions (ktCO₂)* per le emissioni di CO₂ degli interi Stati Uniti: questa scelta semplifica i modelli riducendo la dimensionalità, catturando i trend principali di domanda energetica e decarbonizzazione senza la complessità delle disaggregazioni per fonte, mantenendo però robustezza predittiva.

3 Analisi descrittiva Dataset Studenti

L'analisi descrittiva è stata condotta per esplorare le caratteristiche della popolazione studentesca e individuare le variabili con il maggior impatto sul successo professionale.

3.1 Distribuzione delle Variabili

L'analisi della distribuzione delle feature è un passaggio cruciale per comprendere la natura dei dati e identificare eventuali bias o sbilanciamenti che potrebbero influenzare la fase di modellazione predittiva.

3.1.1 Distribuzione delle variabili

Distribuzione Placement

La distribuzione della variabile target (Figura 3.1) mostra un forte sbilanciamento: circa l'83% degli studenti non ha ottenuto il placement, contro il 17% di casi positivi. Questa marcata asimmetria indica che il placement è un evento relativamente raro nel dataset analizzato. Tale squilibrio ha implicazioni rilevanti non solo a livello descrittivo, ma anche in ottica predittiva, poiché la predominanza della categoria 'non collocato' richiederà specifiche strategie di gestione dello sbilanciamento (class imbalance) nelle fasi di modellazione.




Figure 3.1: *Distribuzione Placement*

Distribuzione IQ

L'analisi della Figura 3.2 mostra che la distribuzione IQ dei non collocati è pressoché simmetrica e centrata sulla media (95-105). Al contrario, gli studenti con placement presentano valori mediamente più elevati, con una maggiore densità tra 110 e 125. Tuttavia, la significativa sovrapposizione tra le due distribuzioni indica che l'IQ non ha una elevata capacità discriminante. In sintesi, un IQ più alto è associato a una maggiore probabilità di placement, ma non costituisce un fattore determinante univoco, inserendosi in un contesto multifattoriale.




Figure 3.2: *Distribuzione IQ*

Disitrbuzione CGPA

L'analisi del CGPA (Figura 3.3) evidenzia una netta separazione tra i due gruppi. Gli studenti non collocati mostrano un'elevata dispersione e un rendimento eterogeneo, senza una concentrazione verso l'eccellenza. Al contrario, il gruppo con placement è decisamente più compatto e orientato verso punteggi elevati, con una variabilità minima. Questa omogeneità suggerisce che un alto rendimento accademico sia un fattore fortemente discriminante: un CGPA elevato e costante non solo aumenta le probabilità di successo, ma definisce un profilo di selezione molto più uniforme rispetto ai non collocati.

Distribuzione Internship

L'analisi dell'esperienza di tirocinio (Figura 3.4) rivela che circa il 60% del campione non ha svolto internship, contro il 40% che ha maturato almeno un'esperienza. Sebbene il tirocinio sia una pratica diffusa, esso non risulta ancora universale, suggerendo un'eterogeneità nei percorsi formativi che potrebbe derivare da differenze motivazionali o di accesso alle opportunità. In sintesi, il dato evidenzia la coesistenza di traiettorie




Figure 3.3: *Distribuzione CGPA*

professionalizzanti distinte: una quota significativa di studenti si affaccia al mercato del lavoro con competenze puramente teoriche, mentre una minoranza rilevante possiede già esperienze pratiche strutturate.




Figure 3.4: *Distribuzione Internship*

Analisi descrittiva delle variabili cognitive e di rendimento accademico

”L’analisi congiunta di IQ e performance accademica (Figura 3.5) evidenzia dinamiche differenti: mentre l’IQ segue una distribuzione normale simmetrica centrata su 100 (range 85-115), le variabili di rendimento mostrano una tendenza verso l’alto. Il CGPA si concentra nelle fasce medio-alte (6-9), così come il Prev_Sem_Result, stabilizzato tra 7 e 9.5. In sintesi, a fronte di un potenziale cognitivo (IQ) distribuito regolarmente nella popolazione, i risultati accademici effettivi tendono a convergere verso livelli costantemente positivi, con una scarsa incidenza di performance insufficienti.”






Figure 3.5: *Distribuzione variabili cognitive e di rendimento accademico*

Analisi descrittiva delle variabili di performance personale e formativa


Le variabili relative a performance accademica, competenze comunicative e attività extra-curricolari mostrano distribuzioni omogenee e prive di forti asimmetrie. In particolare, Academic_Performance e Communication_Skills (entrambe su scala 1-10) presentano frequenze simili in tutto l'intervallo, evidenziando un campione eterogeneo e rappresentativo di ogni fascia di rendimento. Analogamente, l'Extra_Curricular_Score e il numero di Projects_Completed (Figura 3.6) risultano bilanciati tra i vari livelli. Complessivamente, i dati delineano una popolazione studentesca variegata, dove coesistono profili molto distanti tra loro, dai soggetti meno attivi a quelli con elevate esperienze progettuali e accademiche.




(a) *Progetti Completati*



(b) *Abilità nella Comunicazione*



(c) *Punteggio Extra Curriculare*



(d) *Performance Accademica*

Figure 3.6: *Distribuzione delle variabili relative alle competenze e performance degli studenti.*

3.2 Analisi della Correlazione e Multicollinearità

Al fine di indagare le relazioni lineari tra le variabili del dataset e identificare potenziali ridondanze informative, è stata calcolata la matrice di correlazione per tutte le feature numeriche e le variabili categoriche precedentemente codificate. I risultati sono stati visualizzati tramite una heatmap (Figura 3.7), che evidenzia graficamente l'intensità e la direzione delle relazioni.




Figure 3.7: *Matrice di correlazione*

3.2.1 Identificazione della Multicollinearità

L'evidenza statistica più rilevante emersa dall'analisi è la forte multicollinearità tra le variabili CGPA (media dei voti cumulativa) e Prev_Sem.Result (risultato del semestre precedente). Il coefficiente di correlazione tra questi due attributi risulta essere pari a 0.98.

Tale valore indica una relazione quasi perfettamente lineare, suggerendo che le due variabili forniscono la medesima informazione di base. In un contesto di modellazione

statistica e machine learning, mantenere entrambe le variabili introdurrebbe ridondanza, portando a problemi di instabilità nei modelli e a una potenziale distorsione del peso del rendimento scolastico rispetto ad altri fattori. Per tale ragione, nelle fasi successive di classificazione e clustering, è stato deciso di rimuovere la variabile *Prev_Sem_Result*, mantenendo la *CGPA* come feature più rappresentativa dell'andamento accademico globale dello studente.

3.2.2 Analisi delle Correlazioni con il Placement

L'analisi della riga (o colonna) relativa alla variabile target Placement permette di identificare i driver principali del successo lavorativo:

- **Fattori Determinanti:** Le correlazioni positive più significative si riscontrano con la *CGPA* (0.32) e le *Communication_Skills* (0.32). Anche il quoziente intellettivo (*IQ*) mostra un impatto positivo rilevante pari a 0.29. Questi dati confermano che il rendimento accademico, l'intelligenza cognitiva e le abilità comunicative sono i pilastri su cui si basa l'assunzione.
- **Fattori Deboli:** Variabili come *Internship_Experience* e *Extra_Curricular_Score* mostrano coefficienti prossimi allo zero (0.00 e 0.01 rispettivamente). Ciò suggerisce che, limitatamente a questo specifico campione e a un'analisi puramente lineare, queste attività non sembrano costituire un fattore discriminante immediato per l'esito del placement.

3.2.3 L'Anomalia della Variabile Academic_Performance

Un dato inatteso riguarda l'attributo *Academic_Performance*, il quale risulta pressoché totalmente scorrelato da tutte le altre variabili, inclusa la *CGPA* (correlazione pari a 0.00). In una situazione standard, ci si aspetterebbe che una misura di "Performance Accademica" sia strettamente legata alla media dei voti. La totale assenza di legame suggerisce che questa colonna possa riflettere metriche differenti (come la condotta o la frequenza) o rappresentare del rumore statistico privo di potere predittivo significativo per l'analisi in corso.

4 Clustering

L'obiettivo di questo capitolo è illustrare le tecniche di clusterizzazione applicate al dataset per suddividere gli studenti in gruppi con caratteristiche simili, al fine di identificare profili comuni di rendimento e comportamento legati al collocamento lavorativo.

4.1 Algoritmo K-means

Il metodo K-means è stato scelto come tecnica di partizionamento per la sua popolarità e semplicità di applicazione.

4.1.1 Ricerca del numero ottimale di cluster

Per determinare il valore ottimale del parametro K , è stato applicato il metodo di Elbow (gomito), analizzando l'andamento della Within Cluster Sum of Squares (WCSS) per valori di K compresi tra 2 e 10. La scelta del numero di cluster è stata supportata anche dall'analisi del Silhouette Score, una metrica che misura quanto i punti siano ben assegnati al proprio cluster rispetto agli altri. Basandosi sulla grafico in Figura 4.1, la scelta ottima di cluster è ricaduta su $K = 4$.




Figure 4.1: *Elbow Method e Analisi Silhouette*

4.1.2 Analisi dei risultati e profilazione dei cluster

L'analisi delle medie dei parametri per ciascun gruppo ha permesso di definire quattro profili studenteschi ben caratterizzati, evidenziando come diverse combinazioni di competenze influenzino l'esito finale del collocamento. Per facilitare questa analisi, è stata

prodotta una heatmap delle medie delle feature per cluster (Figura 4.2), che permette di visualizzare immediatamente i punti di forza e le criticità di ciascun gruppo.




Figure 4.2: Heatmap delle medie delle feature per cluster

- **Cluster 0 - Eccellenza Accademica e Comunicativa:** Questo gruppo identifica il profilo "Top Performer" del dataset. Gli studenti presentano la media dei voti più elevata ($CGPA \approx 8.86$) e le migliori abilità relazionali ($Communication_Skills \approx 8.05$).
- **Cluster 1 - Orientamento Pratico (Project-Focused):** Questo profilo si distingue per un marcato investimento in attività pratiche. Dalla heatmap in Figura 8 si osserva chiaramente il valore massimo nel numero di progetti completati (media > 4), nonostante un rendimento accademico solo discreto e scarse abilità comunicative.
- **Cluster 2 - Profilo Accademico Debole:** In questo cluster ricadono studenti caratterizzati dalle valutazioni medie più basse del campione ($CGPA \approx 6.10$), pur possedendo doti comunicative discrete.
- **Cluster 3 - Basso Coinvolgimento (At-Risk Students):** Rappresenta la fascia più critica, con un appiattimento generale dei valori verso il basso. La Figura 8 mostra come questi studenti presentino una quasi totale assenza di partecipazione a progetti e abilità comunicative molto limitate.

L'efficacia di questa suddivisione nel riflettere le reali dinamiche di assunzione è confermata dal grafico relativo al tasso di placement per cluster (Figura 4.3).

L'istogramma in Figura 4.3 mostra una correlazione diretta tra i profili identificati e il successo professionale: il Cluster 0 registra il successo maggiore con un tasso di assunzione del 46.1%, valore che crolla drasticamente negli altri gruppi, toccando il minimo nel Cluster 3 (circa 2.4%). Questo confronto costituisce la prova empirica che il mercato del lavoro premi in modo selettivo la combinazione di eccellenza accademica e soft skill rappresentata dal primo cluster.




Figure 4.3: *Tasso di Placement per cluster*

Infine, la visualizzazione dei cluster tramite PCA (Figura 4.4) conferma la validità spaziale di questa ripartizione, mostrando gruppi ben separati tra loro, con le eccellenze (Cluster 0) e gli studenti a rischio (Cluster 3) posizionati ai poli opposti della distribuzione.




Figure 4.4: *Clustering K-Means*

4.2 DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) è stato utilizzato come tecnica di clustering non supervisionata basata sulla densità. A differenza del K-means, questo algoritmo è in grado di identificare cluster di forme irregolari e di isolare i punti che non appartengono a nessuna zona densa, classificandoli come rumore (outlier).

4.2.1 Determinazione degli iperparametri

La scelta degli iperparametri *eps* (raggio del vicinato) e *min_samples* (numero minimo di punti per formare un core point) è stata effettuata seguendo un approccio analitico basato sulla densità locale dei dati.

- **Scelta di *min_samples*:** È stato fissato un valore di $k = 10$ (corrispondente a *min_samples*), basandosi sulla regola empirica che suggerisce un valore superiore al doppio delle dimensioni del dataset (4 feature principali) per rendere l'algoritmo robusto rispetto al rumore.
- **K-distance Graph:** Per individuare il valore ottimale di *eps*, è stato utilizzato il metodo dei K-Nearest Neighbors. Calcolando la distanza di ogni punto dal suo 10-esimo vicino e ordinando tali distanze in modo crescente, è stato generato il K-distance Graph (Figura 4.5).
- **Individuazione del "Gomito":** Il valore di $eps = 0.58$ è stato selezionato in corrispondenza del "gomito" della curva, ovvero il punto in cui la distanza inizia ad aumentare esponenzialmente, indicando che i punti successivi sono troppo isolati per appartenere a un cluster denso.




Figure 4.5: *K-Distance*

4.2.2 Analisi dei risultati ottenuti

L'applicazione di DBSCAN con i parametri ottimizzati ha permesso di mappare la struttura naturale del dataset senza forzare una partizione sferica.

- **Visualizzazione tramite PCA** (Figura 4.6): La proiezione dei dati nello spazio delle prime due componenti principali mostra come l'algoritmo sia riuscito a separare i nuclei densi di studenti dai profili atipici, etichettati come Noise (Cluster -1). I punti di rumore appaiono chiaramente come outlier sparsi ai margini delle distribuzioni principali.




Figure 4.6: *Clustering DBSCAN*

- **Profilazione tramite Heatmap** (Figura 4.7): Attraverso l'analisi delle medie delle feature per ogni cluster identificato da DBSCAN, è stato possibile definire le caratteristiche dei diversi raggruppamenti. Il grafico evidenzia come i cluster densi corrispondano a combinazioni specifiche di IQ, CGPA e Communication Skills, confermando che la densità di studenti si concentra attorno a determinati "archetipi" accademici.




Figure 4.7: *Profilazione DBSCAN*

- **Impatto sul Placement** (Figura 4.8): L'analisi del tasso di collocamento per i cluster DBSCAN ha rivelato una forte eterogeneità. I gruppi con la densità maggiore nelle zone di eccellenza accademica mostrano tassi di successo significativamente più alti, mentre i cluster situati in zone a bassa performance o i punti classificati come rumore presentano probabilità di assunzione minime o nulle.




Figure 4.8: *Rateo Placemete DBSCAN*

L'utilizzo di DBSCAN ha permesso quindi di distinguere tra i pattern comportamentali dominanti e le eccezioni statistiche, fornendo una visione più granulare e meno forzata della popolazione studentesca rispetto agli algoritmi di partizionamento tradizionale.

4.3 Clusterizzazione Gerarchica

L'ultima tecnica di clustering esplorata è la clusterizzazione gerarchica, un metodo che permette di analizzare la struttura dei dati costruendo una gerarchia di raggruppamenti. A differenza delle tecniche di partizionamento, questo approccio consente di visualizzare come i dati si aggregano a diversi livelli di granularità attraverso una rappresentazione ad albero.

4.3.1 Analisi del Dendrogramma

Per individuare la struttura naturale dei dati e determinare il numero ottimale di gruppi, è stato generato un Dendrogramma (Figura 4.9). L'algoritmo è stato implementato utilizzando il criterio del legame di Ward (Ward linkage), finalizzato a minimizzare la varianza totale all'interno di ciascun cluster, e basato sul calcolo della distanza euclidea tra le osservazioni.




Figure 4.9: *Dendrogramma*

L'analisi visiva del dendrogramma ha confermato che una suddivisione in 6 cluster rappresenta il miglior compromesso tra dettaglio e generalizzazione, risultando perfettamente coerente con i risultati precedentemente estratti tramite il metodo K-means.

4.3.2 Risultati e Visualizzazione tramite PCA

Seguendo le indicazioni emerse dall'analisi gerarchica, è stato applicato il modello di AgglomerativeClustering impostando il parametro `n_clusters=6`. Per validare la coerenza spaziale di questa soluzione, è stata prodotta una Visualizzazione tramite PCA (Figura 4.10).

La proiezione dei dati nello spazio delle prime due componenti principali mostra raggruppamenti solidi e ben differenziati. La somiglianza dei cluster gerarchici con quelli identificati dal K-means fornisce un'ulteriore conferma della robustezza dei profili studenteschi analizzati, indicando che la distinzione tra eccellenze, profili tecnici e studenti a rischio è una caratteristica intrinseca e stabile del dataset.




Figure 4.10: *Visualizzazione Cluster Gerarchici*

4.3.3 Analisi dei profili

Per interpretare le caratteristiche dei sei gruppi identificati, è stata prodotta una Heatmap delle medie delle feature (Figura 4.11).

Questa evidenzia come l'algoritmo gerarchico riesca a isolare con estrema precisione gruppi con combinazioni uniche di variabili. Si osservano cluster con picchi esclusivi in Communication Skills o IQ, e gruppi caratterizzati da un bilanciamento medio-alto in tutti i parametri.



Figure 4.11: *Profili HC*

4.3.4 Impatto sul Placement

L'efficacia della suddivisione gerarchica è stata testata tramite il grafico del Tasso di Placement per Cluster_HC (Figura 4.12).

L'istogramma mostra una distribuzione del successo lavorativo molto variegata tra i sei gruppi. Alcuni cluster raggiungono tassi di eccellenza, mentre altri confermano una quasi totale assenza di assunzioni. Questo risultato rafforza le conclusioni tratte con il K-means, dimostrando che indipendentemente dall'algoritmo scelto, il legame tra le feature accademiche aggregate e il successo nel mondo del lavoro rimane la dinamica dominante del dataset.




Figure 4.12: *Placement Rate HC*

5 Classificazione

In questo capitolo viene descritto il processo di classificazione volto a prevedere l'esito del collocamento lavorativo (Placement) degli studenti sulla base delle caratteristiche accademiche e personali disponibili nel dataset.

5.1 Importanza delle Feature

Per ottimizzare il processo di classificazione e comprendere quali fattori influenzino maggiormente la probabilità di assunzione, è stata effettuata un'analisi della Feature Importance sfruttando le proprietà intrinseche del classificatore Random Forest. Questo algoritmo valuta l'importanza di ogni variabile misurando quanto essa contribuisca a ridurre l'impurità (Gini impurity) nei nodi degli alberi decisionali che compongono l'ensemble.

Il grafico a barre risultante (Figura 5.1) evidenzia una chiara gerarchia tra gli attributi:

- **Dominanza dei Risultati Accademici:** La variabile CGPA e il suo stretto correlato Prev_Sem_Result emergono come i predittori più significativi. Questo dato conferma che la media dei voti è il filtro primario utilizzato dai modelli per distinguere tra studenti collocati e non collocati.
- **Rilevanza del Profilo Cognitivo:** Il quoziente intellettivo (IQ) si posiziona immediatamente dopo i risultati accademici, dimostrando come le capacità logico-cognitive rappresentino una componente fondamentale del potere predittivo complessivo.
- **Impatto delle Soft Skill:** Le Communication_Skills mostrano un'importanza rilevante, superiore ad altre variabili pratiche come il numero di progetti o il punteggio extra-curriculare. Questo suggerisce che, per il modello, la capacità di comunicare efficacemente sia un segnale di "collocabilità" più forte rispetto alla mera partecipazione ad attività secondarie.
- **Variabili a Basso Impatto:** Attributi come College_ID, Internship_Experience e Extra_Curricular_Score presentano barre significativamente più basse. In particolare, la scarsa importanza di College_ID conferma la correttezza della scelta di rimuoverlo o minimizzarne il peso, in quanto non fornisce una discriminante robusta per il successo individuale.

Questa analisi ha permesso di concentrare la capacità di apprendimento dei modelli sulle variabili realmente informative ed evitando il rumore causato da feature meno rilevanti.




Figure 5.1: *Importanza Feature*

5.2 Processo di Classificazione

L'obiettivo della fase di classificazione è lo sviluppo di modelli in grado di predire se uno studente otterrà o meno un collocamento lavorativo (Placement) sulla base del suo profilo accademico e cognitivo. Il processo è stato articolato in due fasi: una valutazione preliminare con parametri di default e una successiva ottimizzazione degli iperparametri.

5.2.1 Modelli

Per l'analisi sono stati selezionati i seguenti algoritmi di apprendimento supervisionato:

- **Algoritmi basati su istanze:** Nearest Neighbors (KNN).
- **Macchine a vettori di supporto:** Linear SVM, RBF SVM.
- **Metodi Probabilistici:** Gaussian Process, Naive Bayes (GaussianNB), Quadratic Discriminant Analysis (QDA).
- **Alberi e Ensemble:** Decision Tree, Random Forest, AdaBoost.
- **Reti Neurali:** Multi-layer Perceptron (MLP/Neural Net).

5.2.2 Risultati Preliminari (Senza Ottimizzazione)

Inizialmente, i modelli sono stati addestrati utilizzando i parametri di default. Le prestazioni sono state valutate sul test set (4000 campioni), evidenziando già ottimi risultati per alcuni algoritmi.

Dalla tabella 5.1 si nota come il Gaussian Process e la Reti Neurali abbiano raggiunto la perfezione statistica già in questa fase, indicando una chiara separabilità delle classi nel dataset originale.

Table 5.1: *Performance dei modelli con parametri di default*

Index	Model	Accuracy	F1-Score (Classe 1)
0	Decision Tree	1.00	1.00
1	AdaBoost	1.00	1.00
2	Nearest Neighbors	0.98	0.92
3	RBF SVM	0.98	0.95
4	Random Forest	0.98	0.92
5	Neural Net	0.94	0.80
6	QDA	0.92	0.70
7	Naive Bayes	0.90	0.68
8	Linear SVM	0.90	0.64

5.2.3 Ottimizzazione dei Modelli (Grid Search)

Per massimizzare le prestazioni dei modelli meno performanti e raffinare la robustezza di quelli principali, è stata applicata la tecnica della 5-fold Cross-Validation combinata con la Grid Search.

Iperparametri Ottimali

Il processo di ottimizzazione ha permesso di individuare le configurazioni mostrate di seguito:

- **KNeighborsClassifier:** `metric='manhattan', n_neighbors=9, weights='distance'`.
- **RBF SVM:** `C=10, gamma=1`.
- **DecisionTreeClassifier:** `criterion='entropy', max_depth=5`.
- **RandomForestClassifier:** `n_estimators=50, bootstrap=False, max_depth=None`.
- **MLPClassifier:** `activation='tanh', solver='adam', max_iter=1000`.
- **AdaBoostClassifier:** `learning_rate=0.1, n_estimators=100`.

5.2.4 Confronto Finale dei Risultati

L'ottimizzazione ha portato a un miglioramento significativo, specialmente per i modelli basati su ensemble e alberi, molti dei quali hanno raggiunto l'accuratezza massima, come è possibile vedere dalla tabella 5.2.

Table 5.2: *Performance finali dopo GridSearchCV.*

Model	Accuracy	Miglioramento	Note
Decision Tree	1.00	=	Prestazione stabile
Random Forest	1.00	+2.0%	Incremento significativo
AdaBoost	1.00	=	Prestazione stabile
Neural Net	0.99	+5.0%	Incremento significativo
RBF SVM	0.99	+1.0%	Buona capacità di generalizzazione
QDA	0.92	=	Stabilità nei risultati
Linear SVM	0.91	+1.0%	Limiti intrinseci del kernel lineare

5.2.5 Commento ai risultati

I risultati ottenuti sono estremamente soddisfacenti. L'adozione della Grid Search è stata determinante per algoritmi come Random Forest e Neural Net, che hanno corretto i deficit iniziali raggiungendo un'accuratezza quasi del 100%.

Il successo quasi universale dei modelli (specialmente quelli non lineari) conferma che gli attributi selezionati (CGPA, IQ, Communication Skills) sono indicatori estremamente robusti e deterministici per il collocamento lavorativo nel campione analizzato. Le prestazioni perfette di modelli complessi come il Gaussian Process e il Multi-layer Perceptron suggeriscono che la relazione tra il rendimento accademico e l'assunzione sia modellabile con estrema precisione.

6 Analisi di serie temporali

6.1 Introduzione

In questo capitolo ci concentreremo sull'analisi delle serie temporali applicata al settore energetico, con l'obiettivo di studiare l'evoluzione della produzione di elettricità e delle emissioni di CO₂ negli Stati Uniti d'America nel corso degli anni. Le serie temporali rappresentano uno strumento fondamentale dell'analisi dei dati, poiché consentono di comprendere le dinamiche temporali dei fenomeni osservati e di costruire modelli in grado di prevederne l'andamento futuro.

Per lo sviluppo di questa analisi è stato utilizzato il dataset "US Electricity Generation & Emissions", che raccoglie dati mensili dal 2001 fino al 2025, a livello sia totale che degli stati federali degli Stati Uniti. Il dataset include informazioni dettagliate sulla generazione di energia elettrica (in GWh), sulla capacità installata (in MW) e sulle emissioni associate (in ktCO₂), permettendo un'osservazione completa dell'evoluzione del mix energetico statunitense. Una descrizione più dettagliata del dataset e delle scelte effettuate durante l'analisi si può osservare nella Sezione 2.2.

Grazie all'estensione temporale e alla completezza delle variabili disponibili, è stato possibile costruire e validare modelli di previsione in grado di stimare l'andamento futuro di indicatori chiave, come la produzione elettrica o l'intensità di emissioni di anidride carbonica nel tempo. Questi strumenti predittivi costituiscono una base utile per valutare tendenze, prestazioni ambientali e potenziali scenari di decarbonizzazione del settore energetico.

6.2 Analisi preliminari

Prima di procedere con i modelli di previsione, risulta essenziale condurre un'analisi preliminare del dataset per identificare pattern temporali, trend e relazioni tra le variabili chiave. Questa sezione presenta visualizzazioni esplorative delle serie temporali di produzione elettrica totale e emissioni di CO₂, sia a livello nazionale che per stati selezionati, evidenziando l'evoluzione nel tempo dal 2001 al 2024 (si è escluso il 2025 poiché ci sono dati parziali). Verranno mostrati grafici del mix energetico nazionale, evoluzioni temporali della domanda elettrica e scatter plot per valutare la correlazione tra generazione e emissioni, fornendo basi interpretative per la successiva modellazione predittiva.

6.2.1 Mappe coropletiche informative

Questa sottosezione presenta mappe coropletiche interattive degli Stati Uniti che visualizzano la distribuzione spaziale di tre indicatori chiave: emissioni totali di CO₂, produzione elettrica da fonti rinnovabili e intensità di carbonio, calcolata come rapporto tra emissioni di CO₂ e energia prodotta. Un filtro temporale scorrevole consente di osservare l'evoluzione di questi pattern dal 2001 al 2024, evidenziando gli stati leader/inquinanti in valore assoluto e le transizioni verso una maggiore sostenibilità energetica. Per osservare l'evoluzione temporale si andranno a riportare le mappe filtrate in tre anni: 2001, 2012 e 2024.






Figure 6.1: Mappe coropletiche degli Stati Uniti sulle emissioni di CO₂

Le mappe coropletiche sulle emissioni di CO₂ riportate in Figura 6.1 mostrano la distribuzione spaziale delle emissioni di CO₂ del settore elettrico a livello statale, evidenziando come gli stati con i livelli più elevati di emissioni restino sostanzialmente gli stessi lungo tutto l'orizzonte temporale, con il Texas che emerge costantemente come principale contributore. Osservando la scala cromatica sulla destra, si nota tuttavia una graduale riduzione dei valori massimi associati agli stati più emissivi, indicativa di un lieve trend di diminuzione delle emissioni nel tempo, coerente con una maggiore consapevolezza del problema del riscaldamento globale e con le progressive politiche di mitigazione adottate nel settore energetico statunitense.



(a) Mappa elettricità rinnovabile nel 2001

(b) Mappa elettricità rinnovabile nel 2012



(c) Mappa elettricità rinnovabile nel 2024

Figure 6.2: Mappe coropletiche degli Stati Uniti sulla produzione di elettricità rinnovabile

Le mappe coropletiche relative alla produzione di elettricità rinnovabile riportate in Figura 6.2 mostrano una chiara crescita sia nei livelli assoluti di generazione sia nella diffusione geografica delle fonti rinnovabili. Nel 2001 la produzione risulta concentrata in pochi stati (in particolare sulla costa occidentale), mentre nel 2012 e ancor più nel 2024 la scala dei valori si estende verso livelli significativamente più elevati e un numero crescente di stati assume colori più intensi, indicando una progressiva riconfigurazione del mix energetico statunitense a favore delle rinnovabili.




Figure 6.3: Mappe coropletiche degli Stati Uniti sull'intensità carbonica

Le mappe coropletiche, riportate in Figura 6.3, relative all'intensità carbonica, calcolata come rapporto tra emissioni di CO_2 e generazione di elettricità, mostrano una progressiva riduzione dei valori medi, con un generale passaggio da tonalità più scure a tonalità più chiare in molti stati. Questo andamento suggerisce una diminuzione delle emissioni per unità di energia prodotta, verosimilmente legata sia a una maggiore consapevolezza rispetto al cambiamento climatico sia a un progressivo spostamento verso tecnologie di generazione più efficienti e meno inquinanti, come le rinnovabili. È interessante notare come stati con alti livelli di emissioni totali, come il Texas, non risultino i peggiori in termini di intensità carbonica, lasciando emergere altri stati come più critici quando si considera l'impatto ambientale per kWh prodotto.

6.2.2 Grafici di evoluzione temporale degli stati

In questa sottosezione si analizza l'andamento temporale dei dieci stati con le maggiori emissioni di CO_2 e dei dieci stati con la più elevata generazione di energia elettrica, identificati sulla base dei valori aggregati nel periodo di osservazione. I grafici mettono in evidenza come le traiettorie di crescita o riduzione delle emissioni non sempre seguano in modo proporzionale l'evoluzione della produzione elettrica, permettendo di individuare stati in cui l'aumento della domanda è stato accompagnato da un mi-

grioramento dell'efficienza e del mix energetico, e altri in cui le dinamiche rimangono maggiormente legate alle fonti fossili.




Figure 6.4: *Evoluzione temporale degli stati con più emissioni di CO₂*

Il grafico in Figura 6.4 rappresenta l'evoluzione temporale delle emissioni totali di CO₂ per i dieci stati con i valori più elevati, nel periodo compreso tra il 2001 e il 2024. Si osserva come il Texas rimanga stabilmente lo stato con le emissioni più alte in valore assoluto, pur mostrando una lieve tendenza alla riduzione dopo il picco registrato intorno al 2010, mentre altri stati fortemente emissivi come Florida, Pennsylvania e Ohio presentano curve caratterizzate da una fase iniziale di crescita seguita da una progressiva diminuzione. Gli stati con valori più contenuti (come Kentucky, Alabama, Georgia e West Virginia) mostrano anch'essi un andamento generalmente decrescente negli ultimi anni, evidenziando un trend complessivo di riduzione delle emissioni nel gruppo dei principali emettitori, probabilmente legato a interventi di efficientamento e a cambiamenti nel mix di generazione elettrica.




Figure 6.5: *Evoluzione temporale degli stati con più generazione di elettricità*

Il grafico in Figura 6.5 mostra l'evoluzione temporale della generazione elettrica totale per i dieci stati con i livelli più elevati di produzione nel periodo 2001-2024. Il Texas emerge nettamente come principale produttore, con un trend marcatamente crescente che porta la generazione da circa 370.000 GWh a oltre 560.000 GWh negli ultimi anni, mentre stati come Florida, Pennsylvania e California presentano anch'essi un aumento pressoché continuo, seppur su valori più contenuti. Gli altri stati del gruppo (Illinois, Alabama, New York, Ohio, Georgia e North Carolina) mostrano andamenti più moderati, spesso con fasi di lieve flessione seguite da riprese, delineando nel complesso una crescita generalizzata della produzione elettrica nei principali stati produttori.

6.2.3 Correlazione tra generazione elettrica ed emissioni

In questa sottosezione vengono presentati scatter plot che mettono in relazione, per ciascuno stato, la generazione elettrica totale annuale (in GWh) e le emissioni totali di CO₂ (in ktCO₂), per gli anni 2001, 2012 e 2024. La dimensione dei marker è proporzionale alle emissioni totali di CO₂ dello stato: i pallini più grandi corrispondono quindi agli stati più emissivi in valore assoluto, mentre il colore rappresenta l'intensità carbonica espressa in gCO₂/kWh. Nei grafici vengono inoltre evidenziati e annotati i 10 stati con la maggiore generazione elettrica in ciascun anno, così da confrontare visivamente i principali produttori sia in termini di volume di energia sia in termini di impatto emissivo e di efficienza ambientale.




Figure 6.6: Scatter plot di generazione elettrica ed emissioni di CO_2

Gli scatter plot in Figura 6.6 mostrano, per gli anni 2001, 2012 e 2024, la relazione tra generazione elettrica totale ed emissioni totali di CO_2 per ciascuno stato. In tutti e tre gli anni si osserva una chiara correlazione positiva tra generazione ed emissioni, con il Texas che si colloca sistematicamente nell'area in alto a destra come principale produttore e grande emettitore, ma con un progressivo spostamento di molti stati verso colori meno intensi e, in alcuni casi, verso livelli relativamente più bassi di emissioni a parità di generazione, indicando un miglioramento dell'efficienza e del mix energetico nel tempo.

6.2.4 Evoluzione del mix energetico negli Stati Uniti

In questa sottosezione sono riportati grafici a torta rappresentanti il mix energetico complessivo degli Stati Uniti per gli anni 2001, 2012 e 2024, mostrando la quota di generazione attribuibile alle diverse fonti (fossili, rinnovabili, nucleare, ecc.). Il confronto tra i tre anni permette di evidenziare come il peso relativo delle fonti fossili si riduca progressivamente a favore di rinnovabili e altre tecnologie a minore intensità carbonica, offrendo una visione sintetica delle trasformazioni strutturali del sistema elettrico statunitense nel periodo considerato.




Figure 6.7: Grafici a torta di mix energetici negli Stati Uniti

I grafici a torta in Figura 6.7 mostrano l'evoluzione del mix energetico complessivo degli Stati Uniti nei tre anni 2001, 2012 e 2024, evidenziando una transizione progressiva dalle fonti fossili verso le rinnovabili. Nel 2001 la generazione è dominata dal carbone e, in misura minore, dal nucleare, mentre le rinnovabili rappresentano una quota ancora contenuta; nel 2012 si osserva una riduzione del peso del carbone a favore del gas naturale e di una crescita, seppur graduale, delle fonti rinnovabili. Nel 2024 il quadro cambia in modo più marcato: la quota di carbone si riduce ulteriormente, il gas mantiene un ruolo rilevante ma meno dominante e le rinnovabili assumono una porzione significativamente maggiore del mix, segnalando un percorso di decarbonizzazione strutturale del sistema elettrico statunitense.

6.3 Analisi della Generazione di Elettricità

In questa sezione viene presentata l'analisi completa della serie storica relativa alla generazione totale di energia elettrica negli Stati Uniti. L'obiettivo è comprendere le dinamiche sottostanti, come trend e stagionalità, e costruire un modello predittivo per stimare i valori futuri.

6.3.1 Analisi Esplorativa e Decomposizione

La serie storica analizzata copre il periodo dal 2001 al 2024. Come mostrato in Figura 6.8, la produzione di elettricità presenta una chiara stagionalità annuale, con picchi evidenti nei mesi estivi e invernali, corrispondenti alla maggiore domanda per il raffrescamento e il riscaldamento degli edifici.




Figure 6.8: *Andamento temporale della generazione di elettricità USA (2001-2024)*

Per isolare le diverse componenti, è stata applicata una decomposizione stagionale di tipo additivo. La Figura 6.9 evidenzia:

- Un **trend** che mostra una crescita iniziale fino al 2008, seguita da una fase di sostanziale stabilità con leggere fluttuazioni.
- Una componente **stagionale** molto marcata e regolare, che si ripete ciclicamente ogni 12 mesi.
- I **residui**, che rappresentano la parte di variabilità stocastica non spiegata dal modello.




Figure 6.9: *Decomposizione della serie storica (Trend, Stagionalità, Residui)*

L'analisi della stagionalità è ulteriormente approfondita in Figura 6.10, dove il grafico a linee sovrapposte per anno conferma la ripetitività del pattern mensile. Si osserva sistematicamente un picco principale nei mesi estivi (luglio e agosto) e un picco secondario in inverno (gennaio). Inoltre, con questo grafico si può anche notare il trend crescente che rispetta anch'esso la stagionalità.




Figure 6.10: *Pattern stagionale mensile della generazione elettrica*

6.3.2 Verifica della Stazionarietà

Per l'applicazione dei modelli ARIMA è necessario verificare la stazionarietà della serie. In prima istanza, è stata analizzata la serie originale (non differenziata). Il test *Augmented Dickey-Fuller* (ADF) ha restituito un p-value di 0.23, non permettendo di rigettare l'ipotesi nulla di non-stazionarietà. Questa evidenza è confermata visivamente dai correlogrammi in Figura 6.11: il decadimento estremamente lento della funzione di autocorrelazione (ACF) è un chiaro segnale della presenza di un trend e di non stazionarietà.




Figure 6.11: *ACF e PACF della serie originale (Non Stazionaria)*

Di conseguenza, si è proceduto con una differenziazione stagionale (lag 12), motivata dalla stagionalità annuale osservata nei dati.

Il successivo test ADF sulla serie differenziata ha prodotto un p-value nell'ordine di 10^{-5} , confermando la stazionarietà della serie differenziata.

I nuovi correlogrammi mostrati in Figura 6.12 mostrano ora un decadimento rapido, suggerendo l'idoneità di un modello SARIMA.




Figure 6.12: *ACF e PACF della serie differenziata (Stazionaria)*


6.3.3 Modellazione SARIMA e Validazione

È stato selezionato un modello **SARIMA(1, 0, 0)(1, 1, 0)** con stagionalità di 12 mesi. Questa scelta è stata guidata dai risultati dell'analisi diagnostica preliminare e dai pattern osservati nei correlogrammi della serie.


Il modello è stato addestrato sui dati storici dal 2001 al 2022, riservando il biennio 2023-2024 come set di test.

I risultati della validazione sono illustrati in Figura 6.13. Il modello ha registrato un **Errore Medio Assoluto Percentuale (MAPE) del 3.02%** sul periodo di test, confermando l'elevata capacità predittiva. Un MAPE del 3.02% rappresenta una performance eccellente per previsioni di serie temporali energetiche su orizzonti plurimensili, validando pienamente l'approccio modellistico adottato.

Nel grafico di dettaglio (Figura 6.13b), si nota come le previsioni (linea tratteggiata rossa) seguano fedelmente l'andamento reale (linea blu) per i 24 mesi di test, rientrando quasi sempre nell'intervallo di confidenza.



(a) *Confronto storico: Training vs Test*



(b) *Dettaglio della performance sul set di Test (2023-2024)*

Figure 6.13: *Validazione del modello SARIMA sulla generazione elettrica*

6.3.4 Diagnostica dei Residui

La robustezza del modello è stata verificata tramite l'analisi dei residui, visibile in Figura 6.14. I grafici diagnostici mostrano assenza di pattern temporali, una distribuzione normale e assenza di autocorrelazione residua, confermando che i residui si comportano come *white noise*.





Figure 6.14: *Diagnostica dei residui del modello SARIMA*


6.3.5 Previsione Futura (2025-2026)

Infine, il modello è stato ri-addestrato sull'intero dataset per generare le previsioni future. La Figura 6.15 mostra la proiezione completa fino al 2026.

Per apprezzare meglio la transizione tra dati storici e previsione, la Figura 6.15b propone un dettaglio sulla finestra temporale 2022-2027. La linea tratteggiata rossa prosegue coerentemente il pattern stagionale storico, con un intervallo di confidenza che si allarga progressivamente nel tempo.



(a) *Previsione completa della generazione elettrica (2001-2026)*



(b) *Dettaglio zoomato della previsione (2022-2027)*

Figure 6.15: *Previsione futura con modello SARIMA*

6.4 Analisi delle Emissioni di CO₂

Dopo aver esaminato la generazione di elettricità, l'analisi si sposta sulle emissioni di anidride carbonica derivanti dal settore energetico statunitense.

Inizialmente è stato applicato un modello **SARIMA** univariato sulle emissioni di CO₂, analogo a quello utilizzato per la generazione elettrica, per stabilire un *baseline* predittivo.


Successivamente, è stata condotta un'analisi esplorativa del dataset multivariato per identificare le variabili esogene più fortemente correlate alle emissioni di CO₂. Questa fase ha permesso di selezionare le variabili candidate per l'inclusione nel modello.

Infine, è stato implementato un modello **SARIMAX** che integra le variabili esogene selezionate, con l'obiettivo di valutare se l'approccio multivariato produca un miglioramento significativo rispetto al modello univariato in termini di accuratezza predittiva (MAPE) sul periodo di validazione.


Questa comparazione consente di quantificare l'effettivo contributo informativo delle variabili esogene rispetto alla sola dinamica temporale delle emissioni.

6.4.1 Analisi Esplorativa e Decomposizione

La serie storica delle emissioni (Figura 6.16) mostra un trend decrescente strutturale. La decomposizione evidenzia come, al netto della stagionalità, ci sia una chiara tendenza alla riduzione delle emissioni negli ultimi anni.



(a) *Serie storica emissioni CO_2*



(b) *Decomposizione (Trend, Stagionalità, Residui)*

Figure 6.16: *Panoramica delle emissioni*

Il grafico della stagionalità mostrato in Figura 6.17 conferma i picchi estivi e invernali, ma con un livello assoluto che si abbassa progressivamente anno dopo anno.




Figure 6.17: *Pattern stagionale mensile delle emissioni*

6.4.2 Verifica della Stazionarietà

Anche per le emissioni, la serie originale non è stazionaria (Figura 6.18a). Applicando una differenziazione stagionale, la serie diventa stazionaria, come dimostrato dal rapido decadimento dell'ACF differenziata (Figura 6.18b).





Figure 6.18: *Analisi di autocorrelazione*

6.4.3 Modello 1: SARIMA


Il primo approccio utilizza un modello **SARIMA(1, 0, 0)(1, 1, 0)** con stagionalità di 12 mesi, basato esclusivamente sui dati storici.

La validazione sul set di test (ultimi 24 mesi) mostra un'ottima capacità predittiva,

con un **MAPE del 6.31%**. Questo risultato è evidenziato dal confronto tra dati reali e previsione sia sul lungo periodo che nel dettaglio, come visibile in Figura 6.19



(a) Performance del modello SARIMA (Actual vs Model)



(b) Dettaglio previsione SARIMA vs Actual

Figure 6.19: Validazione del modello SARIMA (Univariato)

6.4.4 Analisi Variabili Esogene

Per migliorare la stima, sono state analizzate le **variabili esogene** che influenzano le emissioni di anidride carbonica. In particolare sono state individuate: la generazione

totale di elettricità, la percentuale di rinnovabili e la percentuale di fossili (carbone e gas). L'evoluzione temporale di tali variabili si può notare in Figura 6.20.

Si nota chiaramente, ad esempio, la correlazione inversa tra l'aumento delle rinnovabili e il calo delle emissioni, andando a dimostrare che questa è una variabile esogena per le emissioni di anidride carbonica.





Figure 6.20: Variabili esogene: Generazione totale, Rinnovabili e Fossili

6.4.5 Modello 2: SARIMAX


Includendo queste variabili esogene in un modello **SARIMAX**, la capacità di catturare le fluttuazioni puntuali migliora decisamente.

Il modello SARIMAX, infatti, ha raggiunto un **MAPE del 1.38%** sul periodo di test (24 mesi), rispetto al 6.31% del modello univariato, corrispondente a una riduzione dell'errore del 78%.

Questa evidenza, visibile nella Figura 6.21, mostra come le variabili esogene consentano al modello di catturare con maggiore precisione le fluttuazioni puntuali e le anomalie rispetto alla sola dinamica temporale storica delle emissioni CO₂.



(a) *Performance del modello SARIMAX (Actual vs Forecast)*



(b) *Dettaglio previsione SARIMAX vs Actual*

Figure 6.21: *Validazione del modello SARIMAX (Multivariato)*

Tuttavia, nonostante il modello SARIMAX multivariato abbia dimostrato una superiorità netta, la sua applicazione operativa per previsioni future presenta una limitazione critica: **le variabili esogene non sono note a priori**. Per effettuare previsioni oltre il periodo di validazione (2024), sarebbe necessario conoscere i valori futuri di tali variabili esogene o stimarle usando modelli predittivi separati, introducendo fonti di incertezza e complessità.

Data questa limitazione pratica, per l'utilizzo operativo si è scelto il modello SARIMA univariato, basato solo sui dati storici delle emissioni di CO₂.

6.4.6 Previsione Futura con Focus 2025-2026

La Figura 6.22 mostra in dettaglio la proiezione per il prossimo biennio generata dal modello scelto. La linea rossa tratteggiata indica la previsione puntuale, mentre l'area ombreggiata in rosso rappresenta l'intervallo di confidenza al 95%.




Figure 6.22: *Previsione emissioni per i prossimi 24 mesi (Focus 2025-2026)*

6.4.7 Diagnostica e previsione completa

La diagnostica dei residui in Figura 6.23 conferma la validità statistica del modello: i residui si distribuiscono normalmente e non presentano autocorrelazione significativa.




Figure 6.23: *Diagnostica dei residui*

Infine, la Figura 6.24 offre la visione d'insieme dell'intera serie storica e della previsione fino al 2026, evidenziando come il modello prolunghi coerentemente il trend e la stagionalità osservati nel passato.




Figure 6.24: *Previsione finale completa (2001-2026)*